Industria: Jurnal Teknologi dan Manajemen Agroindustri
http://www.industria.ub.ac.id
ISSN 2252-7877 (Print) ISSN 2548-3582 (Online)
https://doi.org/10.21776/ub.industria.201x.00x.0x.x

Klasifikasi Mutu Kopi Arabika Berbasis *Image Processing* Menggunakan Metode *Vision Transformer* (ViT)

Aulya Az Zaafirrahman[1*], Aunur Rofiq Mulyarto[1], Usman Effendi[1]
[1]Departemen Teknologi Pertanian, Fakultas Teknologi Pertanian, Universitas Brawijaya
Jl. Veteran No. 1, Malang 65145, Indonesia
[*]zaafirrahman@student.ub.ac.id
Received: xxth xxxxx, 20xx; 1st Revision: xxth xxxxx, 20xx; 2nd Revision: xxth xxxxx, 20xx; Accepted: xxth xxxxx, 20xx

Abstrak

Penerapan syarat mutu dalam proses sortasi biji kopi arabika seringkali menghadapi kendala karena tingginya subjektivitas dan waktu yang dibutuhkan dalam pemeriksaan visual oleh operator sehingga mengakibatkan inkonsistensi terhadap pemeriksaan yang dilakukan. Dengan demikian, diperlukan penerapan *image processing* dalamklasifikasi mutu biji kopi arabika menggunakan *Vision Transformer* (ViT). Penelitian ini bertujuan menentukan konfigurasi arsitektur ViT yang optimal dalam klasifikasi mutu biji kopi arabika berdasarkan sistem nilai cacat berbasis citra digital serta membandingkan performa klasifikasinya dengan algoritma *deep learning* lain. Tahap penelitian dimulai dengan melakukan labelisasi mutu biji kopi arabika berdasarkan SNI 01-2907-2008 yang dilanjutkan dengan akuisisi citra biji kopi dalam *box* akuisisi lalu dilakukan *training, testing,* dan prediksi dengan model ViT. Model ViT menggunakan *transfer learning* dengan *pre-training* dari data global (*ImageNet* dan *Huggingface*) dan *fine-tuning* menggunakan data primer. Model dilatih dan diuji dengan empat proporsi *data train* (80:20, 70:30, 50:50, 40:60) dan dua ukuran *patch* (16x16 px dan 32x32 px). Hasil terbaik dari ViT ImageNet mencapai akurasi 91,67% sedangkan hasil terbaik ViT *Huggingface* mencapai akurasi 90,00%. ViT *ImageNet* dengan akurasi 91,67% lebih unggul dibandingkan CNN *MobileNetV2* yang mencapai akurasi 86,67%. ViT juga lebih cepat dari segi waktu prediksi dengan selisih 2 citra/detik, namun memiliki ukuran model lebih besar sekitar 327 *megabyte* dibandingkan CNN *MobileNetV2.*
Keywords: Biji Kopi Arabika, Klasifikasi Mutu, *Vision Transformation* (ViT)

PENDAHULUAN

Kopi arabika (*Coffea arabica*) mengandung senyawa kimia seperti alkaloid, tanin, saponin, kafein, asam klorogenat, fenol, flavonoid, dan magiferin, serta memiliki kandungan antioksidan yang sangat kuat (Asrina *et al.*, 2021). Komponen-komponen ini memberikan manfaat farmakologis seperti relaksasi otot polos, stimulasi otot jantung, stimulasi sistem saraf pusat, dan pengurangan risiko penyakit neurodegeneratif. Hal ini menjadikan kopi arabika salah satu minuman olahan pertanian yang paling banyak dikonsumsi di dunia (Fajriana dan Fajriati, 2018). Oleh karena itu, penting memperhatikan klasifikasi mutu kopi arabika sesuai tujuannya. Menurut Standar Nasional Indonesia (SNI) 01-2907-2008, standar mutu biji kopi arabika mencakup syarat mutu umum dan khusus berdasarkan karakteristik fisik dan kimia. Karakteristik fisik mencakup keberadaan serangga hidup, kadar kotoran, ukuran biji, aroma, dan sistem nilai cacat, sedangkan karakteristik kimia hanya didasarkan pada kadar air dalam biji kopi.

Syarat mutu khusus biji kopi arabika berdasarkan sistem nilai cacat diklasifikasikan dalam enam tingkatan, dari mutu 1 hingga 6, berdasarkan cacat fisik seperti warna, jumlah kulit kopi, biji pecah dan berlubang, biji bertutul, dan kotoran seperti ranting, tanah, dan batu. Setiap jenis cacat memiliki nilai cacat mulai dari 1/10 hingga 5 per satuan yang diakumulasikan per 300 gram biji kopi. Hasil akumulasi ini menentukan klasifikasi mutu kopi. Proses sortasi visual oleh operator sering kali menghadapi kendala subjektivitas tinggi dan waktu pemeriksaan panjang, menyebabkan inkonsistensi (Zhao et al., 2021).

Deep learning adalah algoritma yang dapat mengekstraksi informasi dari citra digital secara spontan, mempelajari atribut atau fitur menurunkan beban pemrograman, sehingga mempercepat proses pembelajaran tanpa mengorbankan akurasi (Harani dan Hasanah, 2020). Salah satu metode *deep learning* unggul dalam klasifikasi citra digital adalah *Vision Transformer* (ViT), yang menggabungkan konsep *Transformer* ke dalam pengolahan visual. ViT mengubah citra menjadi urutan token yang dipecah

menjadi beberapa *patch* kecil, lalu diproses melalui blok *Transformer* dengan *self-attention* (Dosovitskiy *et al.*, 2020). Pendekatan ini memungkinkan ViT memahami hubungan global antar bagian citra, menghasilkan representasi yang lebih abstrak dan kuat, sehingga mampu menangani berbagai atribut kompleks dalam klasifikasi citra digital (Zhou *et al.*, 2021).

Metode *deep learning* lainnya yang sering digunakan adalah *Convolutional Neural Network* (CNN). CNN menggunakan ekstraksi fitur lokal melalui operasi konvolusi berulang yang diikuti *pooling* untuk mengurangi dimensi peta fitur dalam klasifikasi. Dengan arsitektur yang terdiri dari lapisan konvolusi, *pooling*, fungsi aktivasi, dan *fully connected layer*, menjadikan CNN efektif dalam berbagai tugas visi komputer.

Penelitian ini akan dilakukan klasifikasi mutu kopi arabika (*Coffea arabica*) berdasarkan sistem nilai cacat berbasis *image processing* menggunakan metode ViT. Dengan demikian akan didapatkan model konfigurasi arsitektur ViT yang menghasilkan kinerja terbaik yang dapat diterapkan pada proses klasifikasi mutu biji kopi arabika berdasarkan sistem nilai cacatnya. Harapannya penelitian ini dapat mempersingkat waktu dalam identifikasi mutu kopi arabika berdasarkan sistem nilai cacat dengan konsistensi pemeriksaan yang tetap terjaga.

METODOLOGI

Waktu dan Tempat

Penelitian ini dilaksanakan bulan Februari - Juni 2024. Labelisasi mutu biji kopi arabika dilakukan di Laboratorium Rekayasa Proses Agroindustri. Sementara itu, klasifikasi dengan model ViT dilakukan di Laboratorium Komputasi dan Sistem Agroindustri, Departemen Teknologi Industri Pertanian, Fakultas Teknologi Pertanian, Universitas Brawijaya.

Batasan Penelitian

Penelitian ini memiliki beberapa batasan penelitian diantaranya:

1. Bobot tiap sampel citra direduksi menjadi 10 gram dari bobot asli (300 gram) agar citra dapat terlihat secara jelas saat proses akuisisi dari jarak 15 cm dan luas area 6x6 cm.
2. Pencahayaan yang digunakan terbatas pada lampu LED *stripe* di dalam kotak/*box Chamber of Image Acquirer* (12 *volt* 6-12 lumens fluks).
3. Fokus penelitian terbatas pada tahapan perancangan dan pemilihan arsitektur ViT yang dapat menghasilkan akurasi terbaik dalam mengklasifikasikan mutu biji kopi arabika berdasarkan sistem nilai cacat.

Alat dan Bahan

Penggunaan alat dibagi menjadi tiga kategori, yaitu alat untuk akuisisi citra, alat untuk labelisasi mutu, dan alat untuk melakukan klasifikasi. Untuk alat akuisisi citra, digunakan alat seperti *box* CHIGAR berukuran 30 x 30 x 30 cm, lampu LED (tegangan: 12 Volt, warna: Putih, flux : 16-22 lumens 60 mA), kamera digital Xiaomi Redmi Note 10S (64MP, 26mm (*wide*), 0.7µm), dan kertas HVS putih. Untuk labelisasi mutu, digunakan alat seperti timbangan digital, pinset, dan plastik klip. Untuk alat klasifikasi dengan ViT, digunakan alat seperti *Provider* (*Kaggle Notebook*), Programming Resources (*Phython 3 (Jupyter Notebook IDE)*, RAM (29 GB), GPU (CUDA: *Compute Unified Device Architecture*), *Storage* (73,1 GB), dan *Library* (*PyTorch*). Bahan yang digunakan dalam penelitian ini yaitu biji kopi arabika yang diperoleh dari UMKM Sarie Kopi sebagai bahan utama. Biji kopi arabika yang digunakan merupakan biji kopi dengan jenis *reject* suthon, fixcel, dan menir berukuran 5-7mm.

Prosedur Penelitian

Prosedur penelitian terdiri dari beberapa tahapan, yang diawali dengan identifikasi masalah dan studi literatur, persiapan sampel dan labelisasi mutu, akuisisi citra, konfigurasi arsitektur model ViT, klasifikasi menggunakan ViT, klasifikasi menggunakan metode lain sebagai perbandingan (menggunakan metode CNN atau *Convolutional Neural Network*), analisis hasil dan pembahasan, serta penarikan kesimpulan dan rekomendasi saran. Hasil dari penelitian ini berupa simpulan terkait kinerja arsitektur ViT terbaik dalam mengklasifikasikan mutu biji kopi sesuai dengan sistem nilai cacat.

Persiapan Sampel dan Labelisasi Mutu

Sampel yang digunakan dalam penelitian ini adalah biji kopi arabika dengan tingkatan mutu yang belum diketahui berdasarkan sistem nilai cacatnya. Dengan demikian, diperlukan klasifikasi mutu biji kopi arabika secara manual yang dibagi menjadi enam tingkatan mutu dan diberikan label berdasarkan masing-masing tingkatan mutunya. Tahapan proses labelisasi mutu dimulai dengan menimbang sampel biji kopi arabika hingga mencapai berat sampel 10 gram dan dilakukan sortasi berdasarkan jenis cacatnya. Setelah itu dihitung masing-masing jenis cacatnya sesuai SNI 01-2907-2008 hingga diperoleh total nilai cacatnya. Kemudian dilakukan identifikasi kategori mutu biji berdasarkan syarat nilai cacat dikali 3,33% (sesuai reduksi bobot sampel 10 gram). Terakhir, sampel yang telah dikategorikan tingkatan mutunya dimasukkan ke dalam plastik klip dan diberi label mutu.

Akuisisi Citra

Siapkan sampel biji kopi arabika yang telah dilabeli mutunya dan letakkan di atas kertas HVS putih dalam *box* CHIGAR. Posisikan sampel tegak lurus terhadap kamera dengan jarak 15 cm dan area sampel seluas 6x6 cm^2. Atur kamera sesuai parameter dalam **Tabel 1**. Ambil 10 citra untuk setiap sampel, menghasilkan total 1200 citra dari 120 sampel. Ubah posisi sampel sebelum setiap pengambilan citra berikutnya untuk melatih model agar mengenali sampel dari berbagai sudut pandang. Simpan citra yang telah diakuisisi dalam folder dan lakukan anotasi sesuai tingkatan mutu masing-masing sampel biji kopi arabika.

Tabel 1 Pengaturan Kamera

Jenis Pengaturan	Keterangan
ISO	200
Shutter Speed	1/10
Fokus	*Auto*
Resolusi	1 : 1

Konfigurasi Arsitektur Model Klasifikasi

Rancangan arsitektur ViT terbagi menjadi dua arsitektur transfer learning yang memanfaatkan *pre-training* dari *large dataset* lalu dilakukan *fine-tuning* menggunakan data primer untuk lebih memperkuat model klasifikasi. *Dataset* yang dibandingkan pada arsitektur *transfer learning* yakni *ImageNet* dan *Huggingface*. Masing-masing arsitektur menggunakan *hyperparameter* yang disesuaikan secara *default* oleh masing-masing model ViT yang kemudian dirancang dengan proporsi perbandingan *data training* dan *testing* empat level serta *patch size* sebanyak dua level. Konfigurasi arsitektur model ViT dan rincian jumlah citra digunakan masing-masing dapat dilihat pada **Tabel 2** dan **Tabel 3**.

Tabel 2 Konfigurasi Arsitektur ViT

Konfigurasi	Arsitektur	Proporsi Data	*Patch Size*
IMGT1	ViT/B ImageNet	80 : 20	16
IMGT2			32
IMGT3		70 : 30	16
IMGT4			32
IMGT5		50 : 50	16
IMGT6			32
IMGT7		40 : 60	16
IMGT8			32
HGFC1	ViT/B Hugginface	80 : 20	16
HGFC2			32
HGFC3		70 : 30	16
HGFC4			32
HGFC5		50 : 50	16
HGFC6			32
HGFC7		40 : 60	16
HGFC8			32

Tabel 3 Rincian Jumlah Citra

Proporsi	Label	*Data Train*	*Data Test*
80:20	mutu 1	160	40
	mutu 2	160	40
	mutu 3	160	40
	mutu 4	160	40
	mutu 5	160	40
	mutu 6	160	40
70 : 30	mutu 1	140	60
	mutu 2	140	60
	mutu 3	140	60
	mutu 4	140	60
	mutu 5	140	60
	mutu 6	140	60
50 : 50	mutu 1	100	100
	mutu 2	100	100
	mutu 3	100	100
	mutu 4	100	100
	mutu 5	100	100
	mutu 6	100	100
40 : 60	mutu 1	80	120
	mutu 2	80	120
	mutu 3	80	120
	mutu 4	80	120
	mutu 5	80	120
	mutu 6	80	120

Klasifikasi Menggunakan ViT

Perancangan arsitektur ViT dilakukan menggunakan *Kaggle Notebook* dengan *Python* 3 pada IDE *Jupyter Notebook*. Pemrograman *deep learning* membutuhkan fleksibilitas tinggi, sehingga digunakan *library PyTorch* yang mempermudah proses dan optimalisasi *training* serta komputasi dinamis (Hendri *et al.*, 2021). *Kaggle Notebook* dipilih karena menyediakan berbagai *tools*, ruang penyimpanan besar, dan GPU CUDA gratis yang mempercepat proses training. GPU menjalankan komputasi paralel yang mengolah setiap piksel dalam *image processing* dan membaginya ke setiap *core* GPU (Saputra *et al.*, 2015). Konfigurasi arsitektur model klasifikasi ViT menggunakan *transfer learning* dari *dataset ImageNet* dan *Huggingface.*

a) *Data Splitting*
Data splitting dilakukan dengan membagi data citra menjadi tiga bagian *dataset* yaitu *training*, *testing*, dan *predict*. Tahap ini dilakukan proses *trial* and *error* terhadap rasio jumlah d*ata train, data test,* dan *data predict* dalam pencarian akurasi terbaik

b) *Pre-Training*
Pada tahap ini, dilakukan pembangkitan bobot terlatih menggunakan modul *torchvision* untuk model ViT dengan arsitektur ViT-*Base*. Penggunaan model 'ViT_B_16_Weights.DEFAULT' dan 'ViT_B_32_Weights.DEFAULT' untuk *patch size* 16x16 px dan 32x32 px dari *dataset ImageNet*, serta 'google/vit-base-patch16-224' dan 'google/vit-base-patch32-384' dari *dataset Huggingface*. Pada *ImageNet, pre-training* hanya dapat dilakukan pada ukuran citra 224x224 px untuk *patch size* 32x32 px karena keterbatasan konfigurasi. Bobot terlatih ini digunakan dalam pembuatan model *Pretrained* ViT, diikuti dengan *freezing base parameters* untuk mencegah *update* parameter selama *fine-tuning. Classifier head* dari model diganti menjadi *linear layer* dengan *output* sesuai jumlah *class,* dan *seed* diatur untuk memastikan reproduktibilitas percobaan.

c) *Input* Citra dan Pembuatan *Pre-Trained DataLoaders*
Batch size dideklarasikan sesuai konfigurasi arsitektur yang telah ditentukan, dan dilakukan transformasi menggunakan *transformer* dari *pre-trained weights* untuk mentransformasi data secara otomatis sesuai dengan bobot yang telah di-*pre-trained. Dataloader* dibuat untuk *training* dan *testing,* memuat data dalam *batch,* melakukan pengacakan pada *data training,* dan bekerja secara paralel. *Output* dari proses ini berupa *training dataloader, testing dataloader*, dan nama kelas

berdasarkan *dataset* primer. *Setup dataloader* dilakukan dengan memanggil parameter yang telah disiapkan sebelumnya serta menentukan *batch size.*

d) *Training Preparation*
Model dibuat dengan menggunakan variabel *pre-trained* yang telah disiapkan sebelumnya. *Optimizer* yang digunakan adalah Adam (*adaptive moment estimator*) dengan *hyperparameter* disesuaikan. *Loss function* menggunakan *CrossEntropyLoss* dari *PyTorch* untuk menghitung keakuratan prediksi pada setiap *batch*. Jumlah *epoch* diatur berdasarkan rekomendasi, yaitu 90 *epoch* untuk *ImageNet* dan awalnya 7 epoch untuk *Huggingface*, namun diperpanjang menjadi 50 *epoch* karena model belum konvergen. *Seed* diatur untuk memastikan reproduktibilitas proses *training.*

e) *Fine-Tuning*
Input diteruskan melalui model untuk menghasilkan output, dilanjutkan dengan *backpropagation* untuk memperbarui bobot berdasarkan perbedaan prediksi dengan label. Pada tahap *testing*, model dievaluasi pada *dataset* yang tidak digunakan selama *training* untuk menguji generalisasi model terhadap data baru dengan melakukan *feedforward* tanpa *backpropagation*. Hasil model dengan akurasi terbaik disimpan untuk digunakan pada tahap prediksi.

f) Pengukuran Kinerja Arsitektur
Data untuk mengukur kinerja arsitektur adalah prediksi yang berbeda dengan data yang digunakan untuk *training* dan *testing*. Evaluasi dilakukan berdasarkan parameter fisik mutu biji kopi menggunakan sistem nilai cacat. Hasil prediksi dibandingkan dengan nilai aktual menggunakan *confusion matrix*. Berdasarkan *confusion matrix*, dilakukan perhitungan akurasi untuk mengevaluasi kinerja model.

Perbandingan Performa Klasifikasi dengan CNN

Perbandingan performa klasifikasi dilakukan antara model ViT yang dirancang dengan CNN menggunakan arsitektur *transfer learning MobileNetV2. MobileNetV2* dikenal efisien dalam visi komputer dengan *inverted residuals* dan *linear bottlenecks* (Sandler *et al.*, 2018). Proses klasifikasi CNN mirip dengan ViT, dimulai dengan *data splitting, pre-training* dari *large datasets, input* citra, transformasi, augmentasi, persiapan *training,* dan *fine tuning* dengan data primer selama 50 *epochs.* Evaluasi mencakup grafik *loss,* akurasi, dan hasil prediksi untuk membandingkan performa klasifikasi antara kedua model.

HASIL DAN PEMBAHASAN

Hasil Sampel Biji Kopi Arabika

Sampel biji kopi arabika yang digunakan dalam penelitian ini berasal dari UMKM Sarie Kopi, Kabupaten Malang, dan disuplai dari kebun kopi Gunung Ijen, Kabupaten Banyuwangi. Biji kopi ini tidak dijual berdasarkan klasifikasi SNI, tetapi menggunakan standar pasar seperti suthon, fixcel, dan menir. Spesifikasi biji kopi adalah ditanam di ketinggian lebih dari 1100 mdpl, kadar air sekitar 12%, tingkat keasaman medium, dan berukuran panjang sekitar 5-7 mm dengan warna hijau pucat untuk biji tanpa cacat. Biji kopi yang telah diperoleh kemudian dilabelisasi mutu berdasarkan sistem nilai cacat SNI, dengan cara menggabungkan biji kopi suthon, fixcel, dan menir hingga mencapai bobot 10 gram per sampel. Dari hasil labelisasi, diperoleh 120 sampel dengan rincian tiap kriteria mutu sebanyak 20 sampel yang memiliki jenis mutu berbeda di setiap sampelnya.

Hasil Akuisisi Citra Biji Kopi Arabika

Proses akuisisi citra dari 120 sampel biji kopi arabika diambil sebanyak 10 kali untuk setiap sampel dalam tingkatan mutunya masing-masing sehingga menghasilkan total sebanyak 1200 citra. **Gambar 1** menunjukkan keenam contoh citra biji kopi arabika berdasarkan tingkatan mutunya. Mutu 1 memiliki cacat minimal seperti sedikit biji pecah dan keberadaan kulit kopi. Mutu 2 memiliki sekitar 5% cacat berupa variansi warna dan biji pecah. Mutu 3 memiliki setidaknya 14% cacat termasuk kulit kopi, kulit tanduk, biji hitam/cokelat, biji pecah, dan variansi ukuran. Mutu 4 memiliki setidaknya 22% cacat dengan dominasi variansi warna dan sedikit biji berlubang. Mutu 5 memiliki sekitar 37% cacat yang meliputi kulit kopi, variansi ukuran dan warna, serta biji pecah dan berlubang. Mutu 6 memiliki cacat paling tinggi sekitar 50%, termasuk keberadaan benda asing.

Gambar 1 Citra Biji Kopi Arabika: (a) Mutu 1, (b) Mutu 2, (c) Mutu 3, (d) Mutu 4, (e) Mutu 5, (f) Mutu 6

Hasil Anotasi Citra

Citra biji kopi arabika diakuisisi dan dikelompokkan ke dalam kelas-kelas sesuai dengan tingkatan mutunya. Setelah itu, citra-citra tersebut dikompres dan ditempatkan dalam folder yang telah dilabelisasi berdasarkan tingkatan mutu masing-masing biji kopinya. Anotasi citra biji kopi arabika berdasarkan tingkatan mutunya dapat dilihat pada **Tabel 4.** Anotasi citra biji kopi arabika berdasarkan proporsi data dapat dilihat pada **Tabel 5**.

Tabel 4 Anotasi Citra Biji Kopi Arabika Berdasarkan Tingkatan Mutu

Class	**Label**
Class 1	mutu1
Class 2	mutu2
Class 3	mutu3
Class 4	mutu4
Class 5	mutu5
Class 6	mutu6

Tabel 5 Anotasi Citra Biji Kopi Arabika Berdasarkan Proporsi Data

Class	**Label**
Class 1	80-20
Class 2	70-30
Class 3	50-50
Class 4	40-60

Hasil Arsitektur ViT *Transfer Learning ImageNet*

Tahap klasifikasi citra biji kopi arabika yang melibatkan proses *training* dan *testing* pada arsitektur ViT *Transfer Learning Imagenet* menghasilkan nilai *loss* dan akurasi terbaik pada konfigurasi *patch size* 16x16 px dengan proporsi data 40:60 untuk *training* (*loss*: 0,099; akurasi: 99,8%) dan 80:20 untuk *testing* (*loss*: 0,351; akurasi: 86,25%). Grafik *loss* dan akurasi terbaik disajikan pada **Gambar 2**. Grafik pada **Gambar 2** menunjukkan bahwa selama proses *training*, nilai *loss* dan akurasi mulai konvergen pada *epoch* ke-10 dan stagnan pada *epoch* ke-30, dengan tren penurunan *loss* dan peningkatan akurasi hingga *epoch* ke-90. Namun, hasil testing menunjukkan fluktuasi tanpa perubahan signifikan. Perbedaan signifikan antara hasil *training* dan *testing* menunjukkan indikasi *overfitting*, di mana model terlalu kompleks dan cenderung menghafal data *training*, sehingga kurang mampu menggeneralisasi pola pada data baru. Hasil grafik juga menunjukkan nilai *fitness* yang masuk kategori *overfitting* dengan selisih signifikan antara data *training* dan *testing* (Salman dan Liu, 2019).

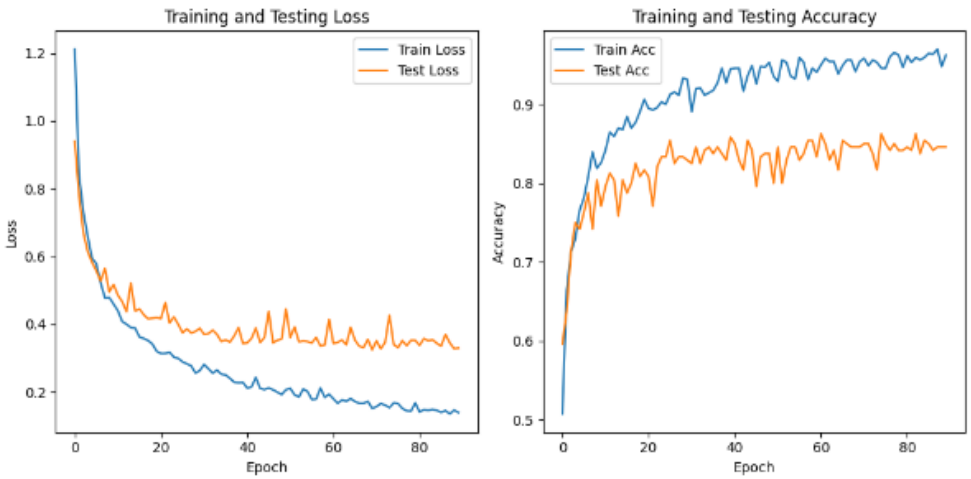

Gambar 2 Grafik *Loss* dan Akurasi *ImageNet* Terbaik
(*Patch Size* 16x16 px dan Rasio *Training:Testing* 80:20)

Seluruh konfigurasi arsitektur ViT *Transfer Learning Imagenet* yang telah dilakukan proses *training* dan *testing* kemudian dilanjutkan dengan prediksi citra biji kopi arabika. Hasil prediksi citra biji kopi arabika kemudian disajikan dalam *confusion matrix*, dengan hasil terbaik dapat dilihat pada **Gambar 3**. Hasil tersebut didapat dari konfigurasi *patch size* 16x16 px dan proporsi data 70:30 yang menunjukkan nilai akurasi prediksi sebesar 91,67% dengan data citra yang diprediksi benar sebanyak 55 data sedangkan yang diprediksi salah sebanyak 5 data. *Confusion matrix* pada **Gambar 3** menunjukkan beberapa kesalahan prediksi pada mutu 1, mutu 3, dan mutu 4, yang mengindikasikan bahwa model melihat kemiripan di antara data citra pada tingkatan mutu yang berdekatan. Kesalahan ini terjadi karena perbedaan visual atau nilai cacat pada sampel biji kopi arabika tidak cukup signifikan. Meskipun demikian, akurasi yang cukup tinggi menunjukkan bahwa model memiliki performa klasifikasi yang baik.

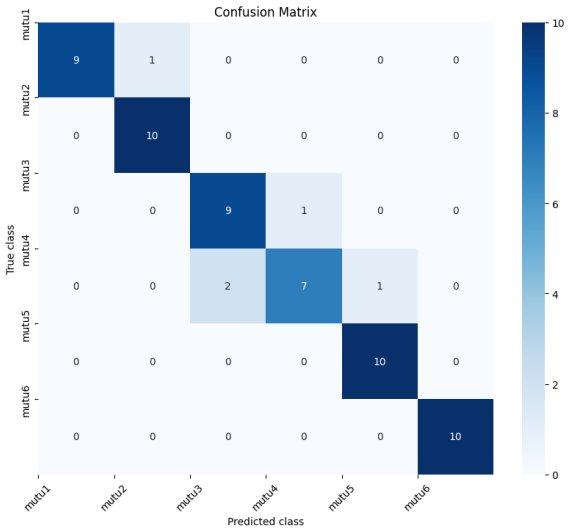

Gambar 4.3 *Confusion Matrix ImageNet* Terbaik
(*Patch Size* 16x16 px dan Rasio *Training:Testing* 70:30)

Hasil Arsitektur ViT *Transfer Learning Huggingface*

Klasifikasi menggunakan arsitektur ViT *Transfer Learning Huggingface* menghasilkan nilai *loss* dan akurasi terbaik pada konfigurasi *patch size* 32x32 px dengan proporsi data 80:20 untuk *training* (*loss*: 0,530; akurasi: 82,71%) dan 80:20 untuk *testing* (*loss*: 0,546; akurasi: 81,67%). Grafik *loss* dan akurasi terbaik disajikan pada **Gambar 4**. Berbeda dengan ViT *ImageNet*, ViT *Huggingface* menunjukkan tren yang lebih stabil dalam hal *loss* dan akurasi, dengan fluktuasi rendah pada **Gambar 4**, menandakan tidak ada deviasi signifikan antar *epoch* selama *training* dan *testing*. Model ViT *Huggingface* mampu

mempelajari data berlabel dan memprediksi kelas citra baru dengan konsisten, meningkatkan performa baik dalam *training* maupun *testing* seiring peningkatan proporsi data training. Grafik menunjukkan bahwa model mulai konvergen pada *epoch* ke-10 dan terus meningkat secara bersamaan hingga *epoch* terakhir dengan selisih yang tidak signifikan. Hasil visualisasi menunjukkan bahwa model terus meningkatkan performa tanpa selisih signifikan antara *training* dan *testing*, menandakan kategori *well-fitting*, di mana model mampu menangkap pola relevan dalam data *training* dan menggeneralisasikannya dengan baik pada data baru (Watanabe dan Yamana, 2021).

Gambar 4 Grafik *Loss* dan Akurasi *Huggingface* Terbaik
(*Patch Size* 32x32 px dan Rasio *Training:Testing* 80:20)

Hasil prediksi citra biji kopi arabika menggunakan arsitektur ViT *Transfer Learning Huggingface* kemudian disajikan dalam *confusion matrix*, dengan hasil terbaik dapat dilihat pada **Gambar 5**. Hasil tersebut didapat dari konfigurasi *patch size* 16x16 px dan proporsi data 80:20 yang menunjukkan nilai akurasi prediksi sebesar 90,00% dengan data citra yang diprediksi benar sebanyak 54 data sedangkan yang diprediksi salah sebanyak 6 data. Berbeda dengan ViT *ImageNet*, ViT *Huggingface* mengalami sedikit lebih banyak kesalahan prediksi, khususnya pada mutu 3 hingga mutu 5, seperti terlihat pada **Gambar 5**. Meskipun ViT *Huggingface* unggul dalam *fitness*, performa *training* dan *testing* ViT *ImageNet* lebih baik, yang berdampak pada prediksi menggunakan data baru. Namun, ViT *Huggingface* tetap memiliki performa yang cukup baik dengan nilai akurasi yang tinggi.

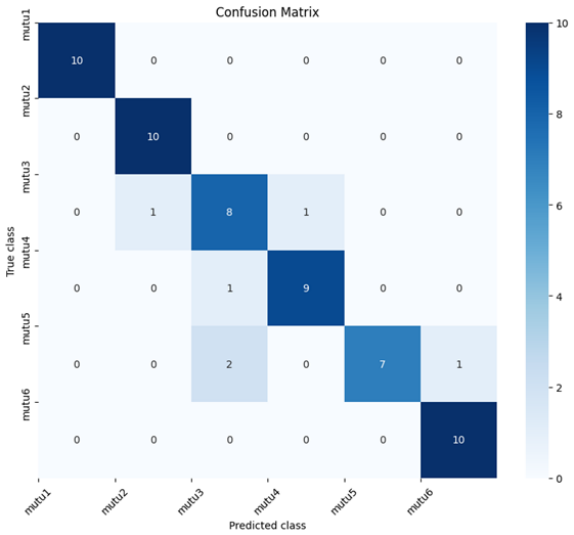

Gambar 5 *Confusion Matrix Huggingface* Terbaik
(Patch Size 16x16 px dan Rasio Training:Testing 80:20)

Pemilihan Arsitektur Terbaik

Pemilihan arsitektur model ViT terbaik dalam penelitian ini didasarkan pada nilai akurasi prediksi masing-masing model. Hasil performa klasifikasi tiap model tercantum pada **Tabel 6**. Peningkatan ukuran *patch size* menurunkan akurasi *testing* dan *prediksi* secara signifikan, tetapi tidak mempengaruhi akurasi *training*, karena informasi yang hilang dari citra dengan *patch size* besar dapat memperburuk performa prediksi (Dosovitskiy *et al*., 2020). Model juga lebih kompleks dengan *patch size* besar sehingga membutuhkan lebih banyak data untuk *training* (Chen *et al*., 2023). Penurunan akurasi antara *training* dan *testing* disebabkan oleh model yang cenderung mempelajari pola global dari citra pada *training* dan pola lokal pada *testing* dan *prediksi* (Paul dan Chen, 2022). Perbedaan akurasi antara *ImageNet* dan *Huggingface* pada *patch size* 32x32 px disebabkan oleh perbedaan ukuran *resizing* citra, dengan *ImageNet* menggunakan 224x224 px dan *Huggingface* 384x384, sehingga *Huggingface* lebih baik pada prediksi *patch size* 32x32 px.

Tabel 6 Performa Klasifikasi Model ViT

Model	*Patch Size* (px)	Proporsi Data	Akurasi *Training* (%)	Akurasi *Testing* (%)	Akurasi *Prediksi* (%)
ViT *ImageNet*	16 x 16	80:20	96,98	86,25	88,34
		70:30	97,02	84,72	91,67
		50:50	98,50	83,50	86,67
		40:60	99,80	79,72	83,34
	32 x 32	80:20	97,29	81,67	76,67
		70:30	97,50	81,67	76,67
		50:50	98,50	79,67	76,67
		40:60	99,58	77,22	61,67
ViT *Huggingface*	16 x 16	80:20	81,11	80,83	90,00
		70:30	81,31	78,05	90,00
		50:50	79,83	75,00	85,00
		40:60	79,58	71,53	83,34
	32 x 32	80:20	82,71	81,67	78,34
		70:30	82,26	79,17	78,34
		50:50	81,33	77,67	80,00
		40:60	79,58	76,94	78,34

Pada model ViT *Transfer Learning ImageNet*, semakin tinggi proporsi data *training* menurunkan akurasi *training* namun meningkatkan akurasi *testing* dan prediksi. Akurasi terbaik diperoleh pada proporsi data 70:30 untuk *patch size* 16x16 px, menunjukkan bahwa model cenderung *overfitting* dengan proporsi data *training* yang tinggi (Dosovitskiy *et al*., 2020). Grafik pada **Gambar 2** mendukung indikasi *overfitting* dengan selisih signifikan antara nilai *loss* dan akurasi. Sementara ViT *Huggingface*, peningkatan ukuran *patch* juga menurunkan performa klasifikasi, namun tidak signifikan dibandingkan *ImageNet*. Peningkatan proporsi data *training* meningkatkan performa klasifikasi, dengan akurasi *training*, *testing*, dan prediksi yang lebih baik. *Huggingface* memiliki dataset lebih besar dan beragam, mengurangi risiko *overfitting* dan meningkatkan kemampuan generalisasi model (Liu *et al*., 2022). Namun, dataset besar juga dapat menyebabkan akurasi lebih rendah saat *fine-tuning* dengan data yang lebih spesifik (El-Nouby *et al*., 2021). Dengan demikian, pemilihan arsitektur model ViT terbaik tidak hanya tergantung pada kemampuan generalisasi dan regularisasi, tetapi juga pada kemampuan adaptasi hasil *pre-training* saat *fine-tuning*. Dari konfigurasi yang ditetapkan, model ViT *ImageNet* dengan *patch size* 16x16 px dan proporsi data 70:30 menunjukkan performa klasifikasi terbaik dengan akurasi prediksi sebesar 91,67%.

Arsitektur Model CNN *MobileNetV2*

Model ViT dengan performa klasifikasi terbaik yang telah didapatkan juga akan dilakukan perbandingan terhadap metode *deep learning* lain yaitu CNN (*Convolutional Neural Network*) menggunakan model *MobileNetV2*. Nilai *loss* dan akurasi terbaik didapat pada konfigurasi proporsi data 50:50 untuk *training* (*loss*: 0,538; akurasi: 80,00%) dan 70:30 untuk *testing* (*loss*: 0,533; akurasi: 78,33%). Grafik *loss* dan akurasi terbaik disajikan pada **Gambar 6**. Performa *training* dan *testing* antara CNN dengan ViT menunjukkan perbedaan mencolok. CNN *MobilNetV2* menunjukkan tren performa yang tidak terarah seiring perubahan proporsi data, berbeda dengan ViT *ImageNet* dan *Huggingface* yang menunjukkan tren yang lebih jelas. Hal ini menunjukkan bahwa CNN tidak terlalu dipengaruhi oleh proporsi data dalam mempelajari pola berlabel atau data baru. Grafik pada **Gambar 6** menunjukkan bahwa model CNN mencapai konvergensi lebih cepat pada epoch ke-5 tetapi mengalami stagnasi dengan fluktuasi tinggi hingga akhir. Meskipun memiliki deviasi performa tinggi, CNN tetap mempertahankan *fitness* antara *training* dan *testing* dengan selisih yang tidak signifikan, menunjukkan kategori *well-fitting*. Performa masing-masing konfigurasi model CNN *MobileNetV2* dapat dilihat pada **Tabel 7**.

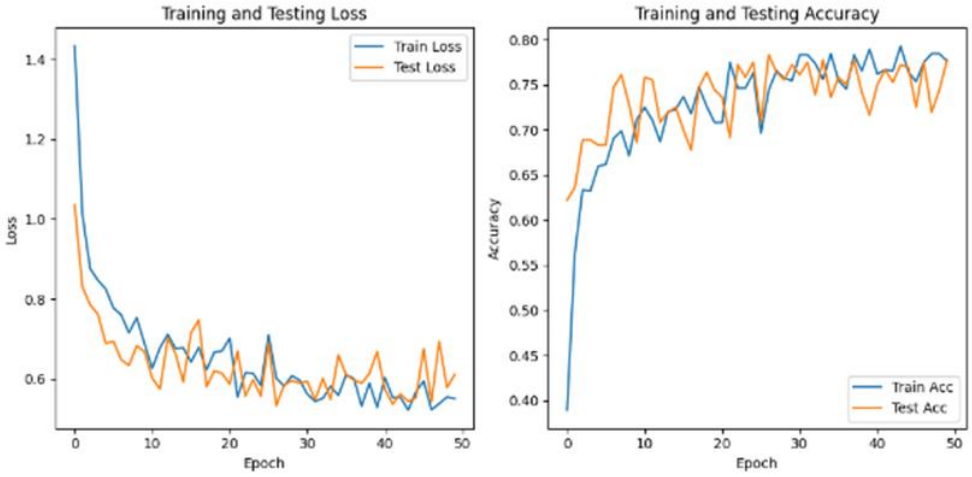

Gambar 6 Grafik *Loss* dan Akurasi *MobileNetV2* Terbaik
(Rasio *Training:Testing* 70:30)

Hasil prediksi citra biji kopi arabika menggunakan arsitektur CNN *MobileNetV2* kemudian disajikan dalam *confusion matrix*, dengan hasil terbaik dapat dilihat pada **Gambar 7**. Hasil tersebut didapat dari konfigurasi proporsi data 40:60 dan 70:30 yang menunjukkan nilai akurasi prediksi sebesar 86,67% dengan data citra yang diprediksi benar sebanyak 52 data sedangkan yang diprediksi salah sebanyak 8 data. **Gambar 7** menunjukkan *confusion matrix* dari model CNN yang banyak melakukan kesalahan prediksi pada tingkatan mutu ketiga, dengan 4 data diprediksi benar dan 6 salah, termasuk 3 data yang diprediksi lebih tinggi dua tingkatan. Ini menunjukkan bahwa CNN berkinerja baik untuk data dengan varians sangat berbeda seperti mutu 1 dan 6, tetapi kurang baik untuk varians rendah seperti mutu 2, 3, dan 4. Hal ini mengindikasikan bahwa CNN cenderung fokus pada representasi lokal tanpa memperhatikan hubungan dengan representasi global dalam citra, sehingga kesulitan saat menangani data citra dengan kemiripan visual tinggi (Dosovitskiy *et al*., 2020).

Tabel 7 Performa Klasifikasi Model CNN

Model	Proporsi Data	Akurasi *Training* (%)	Akurasi *Testing* (%)	Akurasi *Prediksi* (%)
CNN *MobileNetV2*	80:20	79,79	78,33	75,00
	70:30	79,29	78,33	86,67
	50:50	80,00	76,17	81,67
	40:60	79,79	74,17	86,67

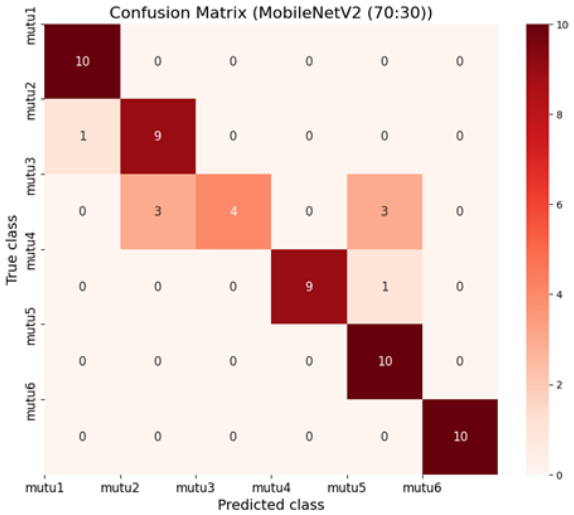

Gambar 7 *Confusion Matrix MobileNetV2* Terbaik
(Rasio *Training:Testing* 70:30)

Perbandingan Performa Klasifikasi ViT dan CNN

Setelah membandingkan performa klasifikasi antara ViT dan CNN, didapati bahwa model ViT dengan *transfer learning ImageNet* (*patch size* 16x16 px dan proporsi data 70:30) mencapai akurasi prediksi terbaik sebesar 91,67%, unggul 5% dibandingkan model CNN *MobileNetV2* dengan akurasi 86,67%. Jika ViT dengan dataset *Huggingface* dimasukkan, akurasi terbaiknya sebesar 90% (*patch size* 16x16 px dan proporsi data 80:20 dan 70:30), tetap lebih unggul 3,33% dibandingkan CNN.

Keunggulan ViT dalam klasifikasi citra dibandingkan CNN terletak pada mekanisme *self-attention* yang memahami hubungan spasial secara global, memungkinkan pemanfaatan informasi kontekstual yang lebih baik daripada konvolusi lokal yang digunakan oleh CNN (Dosovitskiy *et al*., 2020). ViT juga memiliki kapasitas model lebih besar (85 juta parameter) dibandingkan CNN (2 juta parameter), memungkinkan penangkapan pola lebih kompleks dan representasi klasifikasi lebih baik. Selain itu, ViT juga sering kali lebih fleksibel dalam menyesuaikan diri dengan data spesifik pada tahap *fine-tuning* karena mekanisme *self-attention* secara global sehingga dapat mempelajari pola yang lebih spesifik dan relevan dalam proses klasifikasi (Cuenat dan Couturier, 2022). ViT menunjukkan ketahanan dan stabilitas yang lebih tinggi dalam proses *training* dan *testing* dibandingkan CNN yang lebih fluktuatif.

Meskipun ViT unggul dalam performa klasifikasi dibandingkan CNN, keputusan metode terbaik untuk klasifikasi mutu biji kopi arabika juga harus mempertimbangkan kriteria lain yang berperan besar dalam efisiensi operasional sortasi biji kopi. Kriteria tersebut meliputi: 1) Performa klasifikasi, 2) Waktu prediksi, dan 3) Ukuran model dan bobot. Ketiga kriteria ini penting untuk meningkatkan efisiensi operasional pemasok biji kopi dalam proses sortasi berdasarkan sistem nilai cacat. Performa klasifikasi menentukan kualitas akurasi model, sementara waktu prediksi dan ukuran model mempengaruhi kecepatan prediksi dan beban komputasi. Perbandingan antara ViT dan CNN berdasarkan kriteria ini dapat dilihat pada **Tabel 8**.

Tabel 8 Perbandingan Kriteria Operasional ViT dan CNN

Metode	Akurasi (%)	Waktu Prediksi (*s/img*)	Ukuran Model dan Bobot (Mb)
ViT *ImageNet*	91,67	0,165	335,230
ViT *Huggingface*	90,00	0,163	335,251
CNN *MobileNetV2*	86,67	0,223	8,964

KESIMPULAN

Klasifikasi mutu biji kopi arabika menggunakan metode ViT berdasarkan sistem nilai cacatnya dilakukan dengan dua model berbeda: ViT *Transfer Learning* dengan *dataset ImageNet* dan *Huggingface*. Model ViT *ImageNet* mencapai akurasi terbaik sebesar 91,67% dengan konfigurasi *patch size* 16x16 px dan proporsi data *train:test* 70:30, sementara ViT *Huggingface* mencapai akurasi terbaik sebesar 90,00% dengan *patch size* 16x16 px dan proporsi data *train:test* 80:20 dan 70:30. Berdasarkan hasil penelitian, konfigurasi ViT *ImageNet* dengan *patch size* 16x16 px dan proporsi data 70:30 merupakan konfigurasi terbaik untuk klasifikasi mutu biji kopi arabika berdasarkan sistem nilai cacatnya. Hasil model ViT terbaik kemudian dibandingkan dengan metode *deep learning* lain yaitu CNN menggunakan model *transfer learning MobileNetV2*, yang memiliki akurasi terbaik sebesar 86,67% pada proporsi data *train:test* 70:30. Setelah dilakukan perbandingan, ViT masih lebih unggul dengan selisih akurasi 5%. Dalam konteks operasional sortasi biji kopi arabika, ViT memiliki waktu prediksi lebih cepat dengan selisih 2 citra/detik dibandingkan CNN, namun ukuran model ViT yang lebih besar sebesar 320 MB membuat beban komputasinya jauh lebih tinggi.

REFERENSI

Asrina R, Zulfiah Z, Kamal SE, Roosevelt A, Patandung G, Murniati M, Amiruddin A, Djajanti AD, Rusli R. 2021. Aktivitas antioksidan pada kopi arabika (Coffea arabica L.) yang diolah dengan mesin espresso dan manual brew pour over V60. Media Farmasi 17(2) : 204-210.

Chen M, Lin M, Li K, Shen Y, Wu Y, Chao F, Ji R. 2023. Cf-vit: A general coarse-to-fine method for vision transformer. In Proceedings of the AAAI Conference on Artificial Intelligence 37(6) : 7042-7052.

Cuenat S, Couturier R. 2022. Convolutional neural network (cnn) vs vision transformer (vit) for digital holography. International Conference on Computer, Control and Robotics (ICCCR) 1(1) : 235-240.

Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X, Unterthiner T, Dehghani M, Minderer M, Heigold G, Gelly S, Uszkoreit J. 2020. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

El-Nouby A, Izacard G, Touvron H, Laptev I, Jegou H, Grave E. 2021. Are large-scale datasets necessary for self-supervised pre-training?. arXiv preprint arXiv 21(12) : 10740.

Fajriana NH, Fajriati I. 2018. Analisis kadar kafein kopi Arabika (Coffea arabica L.) pada variasi temperatur sangrai secara spektrofotometri ultra violet. Analit: Analytical and Environmental Chemistry 3(2) : 1-15.

Harani NH, Hasanah M. 2020. Deteksi Objek dan Pengenalan Karakter Plat Nomor Kendaraan Indonesia Berbasis Python. Kreatif Industri Nusantara, Bandung.

Hendri H, Hoki L, Augusman V, Aryanto D. 2021. Penerapan machine learning untuk mengategorikan sampah plastik rumah tangga. Jurnal Technology Informatics & Computer System 10(1): 1-5.

Liu Z, Xu Y, Xu Y, Qian Q, Li H, Ji X, Chan A, Jin R. 2022. Improved fine-tuning by better leveraging pre-training data. Advances in Neural Information Processing Systems 35(1) : 32568-32581.

Paul S, Chen PY. 2022. Vision transformers are robust learners. In Proceedings of the AAAI conference on Artificial Intelligence 36(2) : 2071-2081.

Salman S, Liu X. 2019. Overfitting mechanism and avoidance in deep neural networks. arXiv preprint arXiv 1(1) : 6566.

Sandler M, Howard A, Zhu M, Zhmoginov A, Chen LC. 2018. Mobilenetv2: Inverted residuals and linear bottlenecks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition 1(1) : 4510-4520.

Saputra M, Kusrini K, Kurniawan MP. 2020. Identifikasi mutu biji kopi arabika berdasarkan cacat dengan teknik Convolutional Neural Network. Jurnal Teknologi Informasi dan Komunikasi 10(1): 27-35.

Watanabe S, Yamana H. 2021. Overfitting measurement of deep neural networks using no data. International conference on data science and advanced analytics (DSAA) 1(1) : 1-10.

Zhao G, Quan L, Li H, Feng H, Li S, Zhang S, Liu R. 2021. Real-time recognition system of soybean seed full-surface defects based on deep learning. Computers and Electronics in Agriculture 179(1): 1-9.

Zhao Z, Wu X, Liu H. 2022. Vision transformer for quality identification of sesame oil with stereoscopic fluorescence spectrum image. LWT 158(1) : 113173.

Zhou D, Kang B, Jin X, Yang L, Lian X, Jiang Z, Hou Q, Feng J. 2021. Deepvit: Towards deeper vision transformer. arXiv preprint : 2103.11886.